

Le projet porte sur l'**analyse de données e-commerce** à l'aide de **Spark** (via l'API **PySpark**). Il inclut à la fois une **approche non supervisée** (clustering) et une **approche supervisée** (classification ou régression), afin d'évaluer les compétences Big Data et Machine Learning

Examen Final : Analyse et Modélisation Big Data avec PySpark

Contexte

Vous travaillez pour une plateforme e-commerce qui enregistre chaque transaction client (facture, produit, quantité, date, etc.). L'entreprise souhaite :

1. **Segmenter** sa clientèle en groupes homogènes (clustering non supervisé).
2. **Prédire** un comportement clé des clients (modèle supervisé) pour cibler les actions marketing.

Pour cela, vous disposez d'un jeu de données similaire à l'exemple "Online Retail" contenant:

- **InvoiceNo** : identifiant unique de la facture
- **StockCode** : identifiant du produit
- **Description** : description du produit
- **Quantity** : nombre d'unités achetées
- **InvoiceDate** : date et heure de l'achat
- **UnitPrice** : prix unitaire du produit
- **CustomerID** : identifiant unique du client
- **Country** : pays d'où la commande a été passée

Vous pouvez utiliser un **notebook PySpark local**, (ou **Google colab**, si vous préférez) pour **traiter** et **analyser** ces données avec **PySpark**.

Livrables attendus

1. Un **notebook PySpark** (fichier `.ipynb`) contenant :
 - o Tout le **code** nécessaire (chargement des données, transformations, visualisations, entraînement des modèles, etc.).
 - o Des **commentaires** et **analyses** expliquant vos choix et interprétations.
 2. Un **rapport** sous forme de **slides** résumant :
 - o Les **étapes** clés du projet.
 - o Les **résultats** principaux.
 - o Les **recommandations** (ou actions) pour l'entreprise.
-

Objectifs pédagogiques

1. Maîtriser les **opérations de base** sur un DataFrame PySpark (lecture, filtres, agrégations, jointures).
 2. Réaliser une **analyse exploratoire** (EDA) à grande échelle.
 3. Mettre en place un **clustering** (autre que K-Means) pour segmenter les clients (non supervisé) :
 - a) **GaussianMixture** (GMM),
 - b) **BisectingKMeans**,
 - c) **Hierarchical Clustering** (via `pyspark.ml.clustering.BisectingKMeans` pour s'en approcher)
 4. Construire un **modèle supervisé** (classification ou régression) pour prédire un comportement ou une variable d'intérêt.
 5. Utiliser des **méthodes d'évaluation** adaptées (coût WSSSE, Silhouette pour le clustering, précision / F1 / RMSE pour la partie supervisée, etc.).
 6. Synthétiser les résultats et proposer des **actions concrètes**.
-

Plan de Travail

1) Initialisation & Chargement des données

- **Installer** et **configurer** PySpark (si nécessaire) dans Google Colab.
- **Charger** le fichier CSV (ou Parquet) e-commerce dans un DataFrame PySpark.
- Vérifier la **structure** (schéma) et le **nombre de lignes**.

2) Exploration & Prétraitement

- Afficher des **statistiques descriptives** : nombre de clients distincts, distribution du Quantity, etc.
- Vérifier la présence de **valeurs manquantes** ou anormales et décider du traitement (filtrage, imputation, etc.).
- Convertir la colonne `InvoiceDate` en **Timestamp**.
- (Optionnel) Créer de nouvelles colonnes si besoin (ex. `total par ligne = Quantity * UnitPrice`).

3) Segmentation Client (Non Supervisé)

1. **Création de variables RFM** (Recency, Frequency, Monetary) :
 - o Recency : nombre de jours (ou secondes) depuis la dernière commande.
 - o Frequency : nombre total de commandes passées.
 - o Monetary : total dépensé par client.
2. **Regrouper** ces variables RFM dans un DataFrame PySpark par client.
3. **Assembler** et **standardiser** ces features (VectorAssembler + StandardScaler).
4. **Entraîner** un des 3 algos non supervisé proposé dans les objectifs :

- o Déterminer le **nombre optimal** de clusters (méthode du coude ou indice silhouette ?).
- o Obtenir les **centroïdes** et **assigner** chaque client à un cluster.
- 5. **Analyser** les segments :
 - o Moyenne de `recency`, `frequency`, `monetary` par cluster.
 - o Interpréter les groupes (clients fidèles, gros dépensiers, etc.).

4) Modélisation Supervisée

Vous allez maintenant construire un **modèle prédictif**. Plusieurs choix possibles :

- **Classification** : prédire si un client est un “gros dépensier” (1) ou “petit dépensier” (0), en définissant un **seuil** sur `monetary_value`.
 - o Ex. Label = 1 si `monetary_value` > 500, sinon 0.
- **Ou** : prédire si un client **revient** dans le mois suivant (churn vs non-churn) en définissant un label binaire.
- **Ou** : une **régression** pour estimer la `monetary_value` à partir de variables comme `frequency`, `country`, etc.

Tâches :

1. **Choisir** la cible (label) et les features.
2. Diviser le dataset en **train** / **test** (ex. 70% - 30%).
3. **Assembler** les features dans un vecteur (VectorAssembler).
4. **Entraîner** un ou plusieurs algorithmes (LogisticRegression, RandomForest, ou autre) sur le **jeu d’entraînement**.
5. **Évaluer** les performances sur le jeu de **test** :
 - o Pour la **classification** : accuracy, precision, recall, F1, matrice de confusion, etc.
 - o Pour la **régression** : RMSE, MAE, R².
6. (Optionnel) **Optimisation** des hyperparamètres via CrossValidator ou TrainValidationSplit.

5) Visualisations & Recommandations

- Illustrer vos **résultats** (clustering et classification) avec des graphiques (histogrammes, barplots, etc.).
- Proposer des **actions** ou **recommandations** :
 - o Par exemple, cibler un cluster spécifique pour des offres marketing.
 - o Ou définir un plan pour convertir les “petits dépensiers” en “gros dépensiers”.
 - o Expliquer comment le modèle supervisé peut être intégré dans un pipeline de recommandation.

6) Conclusion

- **Récapituler** les points clés :
 - Principaux **segments** de clients trouvés.
 - Performance du **modèle supervisé**.
 - Limitations (taille du dataset, variables disponibles, etc.).
 - Pistes d'amélioration (plus de données, fonctionnalités supplémentaires, etc.).
-

Conseils & Critères d'Évaluation

1. **Propreté du code** :
 - Utilisation correcte de PySpark (DataFrame API, SparkSession, transformations, actions).
 - Organisation en cellules/commentaires clairs.
 2. **Rigueur de l'analyse** :
 - Cohérence dans la gestion des données manquantes.
 - Justification des choix de features, du nombre de clusters, etc.
 3. **Qualité des visualisations** :
 - Graphiques pertinents pour illustrer les segments et la performance du modèle.
 4. **Évaluation du modèle supervisé** :
 - Mise en place d'une validation appropriée (train/test).
 - Interprétation des résultats (précision, F1-score, etc.).
 5. **Pertinence des recommandations** :
 - Lien entre les résultats et les actions possibles pour l'entreprise.
 6. **Autonomie et esprit critique** :
 - Propositions de pistes d'amélioration.
 - Explications sur les éventuelles difficultés rencontrées.
-

Format de Rendu

- Un **notebook .ipynb** (Google Colab ou Jupyter)
 - Des slides d'une **dizaine** de pages récapitulant :
 - Le **processus** global, les différentes étapes (EDA, clustering, modèle supervisé)
 - Les **résultats** et **conclusions**
-

Bon courage !

